实验三 CIFAR10图像分类

2022年10月2日

1. 读取数据文件

使用torchvision.datasets的CIFAR10数据集,训练集进行旋转和裁剪操作。用DataLoader的方式分批读取

实现训练和测试函数

```
In [4]: # 每个epoch的训练结果

def train_epoch(model,dataloader):
    model.train()
    running_loss = 0
    for i,(img,label) in enumerate(tqdm(dataloader)):
        img,label = img,to(device),label.to(device)
        out = model(img)
        optimizer.zero_grad()
        loss = criterion(out,label) # 模型例始结果
        voriental # 计算级生 # 反向性相型影梯度
        running_loss + loss.item() * img.size(0)
        return running_loss / len(dataloader.dataset)

In [5]:

def test(model,dataloader):
        model.eval()
        total = 0
        correct = 0
        correct = 0
        for i,(img,label) in enumerate(tqdm(dataloader)):
        img,label = img.to(device),label.to(device)
        out = model(img)
        __ , pred = torch.max(out,1)
        correct += (pred == label).sum().item()
        total += label.size(0)
        acc = 100.0 * correct / total
        return acc

In [6]:

def train(model, n_epochs):
        loss = train_epoch(model, train_loader)
        acc = test(model, train_loader)
        acc = test(model, train_loader)
        acc = test(model, train_loader)
        print('Epoch', Train loss {}', Train Acc {}'.format(epoch + 1, loss, acc))
        loss_arr.append(loss)
        acc_arr.append(loss)
        acc_arr.append(loss)
        acc_arr.append(loss)
```

2. MLP模型搭建

搭建了具有3个全连接层的MLP,隐含层结点分别为1024, 256, 用ReLU作为 隐含层的激活函数。

```
MLP模型搭建
In [7]: class MLP(nn.Module):
    def __init__(self):
        super(MLP, self).__init__()
        self.fc1 = torch.nn.Linear(3 * 32 * 32, 1024)
        self.fc2 = torch.nn.Linear(1024, 256)
        self.fc3 = torch.nn.Linear(256, 10)

def forward(self, x):
        x = x.view(-1, 3 * 32 * 32)
        x = F.relu(self.fc1(x))
        x = F.relu(self.fc2(x))
        x = self.fc3(x)
        return x
```

使用CrossEntropyLoss作为损失函数,使用学习率为0.01,衰退权重为0.0001的SGD优化器进行训练。50次迭代后的预测正确率为54.9%。

3. CNN模型搭建

搭建了具有3个卷积层和池化层,以及3个全连接层的卷积神经网络输入的是3 * 32 * 32的数据

第一个卷积层使用6 * 5 * 5的卷积核,输出6 * 28 * 28

第一个池化层进行2*2的最大池化,输出6*14*14

第二个卷积层使用16 * 3 * 3的卷积核,输出16 * 12 * 12

第二个池化层进行2*2的最大池化,输出16*6*6

第三个卷积层使用64*2*2的卷积核、输出64*4*4

第三个池化层进行2*2的最大池化,输出64*2*2

后面接入三个全连接层,隐含层使用ReLU作为激活函数。

```
CNN模型搭建

In [9]:

class CNN(nn.Module):
    def __init__(self):
        super(CNN, self).__init__()
        self.conv1 = nn.Conv2d(3, 6, 5)  # 6 * 28 * 28
        self.pool1 = nn.MaxPool2d(2)  # 6 * 14 * 14
        self.conv2 = nn.Conv2d(6, 16, 3)  # 16 * 12 * 12
        self.pool2 = nn.MaxPool2d(2)  # 16 * 6 * 6
        self.conv3 = nn.Conv2d(16, 64, 3)  # 64 * 4 * 4
        self.pool3 = nn.MaxPool2d(2)  # 64 * 2 * 2
        self.fc1 = nn.Linear(64 * 2 * 2 , 1024)
        self.fc2 = nn.Linear(1024, 256)
        self.fc3 = nn.Linear(1024, 256)
        self.fc3 = nn.Linear(256, 10)

def forward(self, x):
        x = self.pool3(F.relu(self.conv1(x)))
        x = self.pool3(F.relu(self.conv3(x)))
        x = x.view(-1, 64 * 2 * 2)
        x = F.relu(self.fc1(x))
        x = F.relu(self.fc2(x))
        x = self.fc3(x)
        return x
```


使用CrossEntropyLoss作为损失函数,使用学习率为0.01,衰退权重为0.0001的SGD优化器进行训练。50次迭代后的预测正确率为74.03%。

3. 绘制变化曲线

使用前两个实验的代码

```
import matplotlib.pyplot as plt
def plot_loss_and_acc(loss_and_acc_dict):
    # visualize loss curve
    plt.figuref(jasize=(12, 5))
    min_loss, max_loss = 100.0, 0.0
    for key, (loss_list, acc_list) in loss_and_acc_dict.items():
        min_loss = min(loss_list) if min(loss_list) < min_loss else min_loss
        max_loss = max(loss_list) if max(loss_list) > max_loss else max_loss
        num_epoch = len(loss_list)
        plt.plot(range(1, 1 + num_epoch), loss_list, '-s', label=key)
    plt.xlabel('Epoch')
    plt.ylabel('Loss')
    plt.legend()
    plt.xticks(range(0, num_epoch + 1, 2))
    plt.axis([0, num_epoch + 1, min_loss - 0.1, max_loss + 0.1])
    plt.show()
    # visualize acc curve
    plt.figuref(jasize=(12, 5))
    min_acc, max_acc = 100.0, 0.0
    for key, (loss_list, acc_list) in loss_and_acc_dict.items():
        min_acc = min(acc_list) if min(acc_list) < min_acc else min_acc
        max_acc = max(acc_list) if max(acc_list) > max_acc else max_acc
        num_epoch = len(acc_list)
        plt.plot(range(1, 1 + num_epoch), acc_list, '-s', label=key)
    plt.xlabel('Epoch')
    plt.ylabel('Accuracy')
    plt.legend()
    plt.xticks(range(0, num_epoch + 1, 2))
    plt.axis([0, num_epoch + 1, min_acc, max_acc + 1])
    plt.show()
```

从结果中可以看出,CNN的loss更小,而且正确率也比MLP的要高20%




4. 调整优化器

使用学习率为0.001的Adam优化器训练



与使用SGD优化器对比为:



可以看出一开始Adam优化器的损失下降的较快,但是随着epoch的增加, adam的损失则变化得较小,而SGD的正确率也逐渐超过Adam。


5. 调整网络层数

增加一个全连接层,并在全连接层之间添加了一个dropout层。

```
class CNNNew(nn.Module):
    def __init__(self):
        super(CNNNew, self).__init_
        self.conv1 = nn.Conv2d(3, 6, 5)
                                            # 6 * 28 * 28
        self.pool1 = nn.MaxPool2d(2)
                                            # 6 * 14 * 14
                                            # 16 * 12 * 12
        self.conv2 = nn.Conv2d(6, 16, 3)
        self.pool2 = nn.MaxPool2d(2)
                                            # 16 * 6 * 6
        self.conv3 = nn.Conv2d(16, 64, 3)
                                            # 64 * 4 * 4
        self.pool3 = nn.MaxPool2d(2)
                                            # 64 * 2 * 2
        self.fc1 = nn.Linear(64 * 2 * 2 , 2048)
        self.fc2 = nn.Linear(2048, 512)
        self.fc3 = nn.Linear(512, 256)
        self.fc4 = nn.Linear(256, 10)
    def forward(self, x):
       x = self.pool1(F.relu(self.conv1(x)))
        x = self.pool2((self.conv2(x)))
       x = self.pool3(F.relu(self.conv3(x)))
        x = x.view(-1, 64 * 2 * 2)
        x = F.relu(self.fc1(x))
       x = F.relu(self.fc2(x))
       x = F.dropout(x, 0.3)
                                             # 增加dropout层
       x = F.relu(self.fc3(x))
       x = self.fc4(x)
        return x
```

使用CrossEntropyLoss作为损失函数,使用学习率为0.01,衰退权重为0.0001的SGD优化器进行训练。50次迭代后的预测正确率为73.13%。

与原来CNN的对比中,可以看到两者曲线基本一致,并没有看出增加层数带来的效果。



6. 修改隐含层激活函数

将隐含层激活函数替换为Tanh

```
class CNNTanh(nn.Module):
    def __init__(self):
         super(CNNTanh, self).__init__()
self.conv1 = nn.Conv2d(3, 6, 5)
self.pool1 = nn.MaxPool2d(2)
                                                    # 6 * 28 * 28
                                                    # 6 * 14 * 14
         self.conv2 = nn.Conv2d(6, 16, 3)
                                                    # 16 * 12 * 12
         self.pool2 = nn.MaxPool2d(2)
                                                    # 16 * 6 * 6
         self.conv3 = nn.Conv2d(16, 64, 3)
                                                    # 64 * 4 * 4
         self.pool3 = nn.MaxPool2d(2) # self.fc1 = nn.Linear(64 * 2 * 2 , 1024)
                                                    # 64 * 2 * 2
         self.fc2 = nn.Linear(1024, 256)
         self.fc3 = nn.Linear(256, 10)
    def forward(self, x):
         x = self.pool1(F.relu(self.conv1(x)))
         x = self.pool2((self.conv2(x)))
         x = self.pool3(F.relu(self.conv3(x)))
         x = x.view(-1, 64 * 2 * 2)
         x = F.tanh(self.fc1(x))
         x = F.tanh(self.fc2(x))
         x = self.fc3(x)
         return x
```

```
cnn = CNNTanh().to(device)
criterion = nn.CrossEntropyLoss().to(device)
optimizer = torch.optim.SGD(params=cnn.parameters(), lr=0.01, weight_decay=0.0001)
cnn_tanh_loss, cnn_tanh_acc = train(cnn, n_epochs)
print('Test Acc: {}'.format(test(cnn, test_loader)))

100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
100%|
```

对比中,可以看出,ReLU作为激活函数的效果要更好一点。

